

資料探勘-第一次作業

1. List the top 20 apps with the largest size. Present the app names and their size.

```
1 Top 20 Apps with the largest Size:
2 App: Mini Golf King – Multiplayer Game, Size: 100M, Size_MB: 100.0
3 App: Ultimate Tennis, Size: 100M, Size_MB: 100.0
4 App: Hungry Shark Evolution, Size: 100M, Size_MB: 100.0
5 App: SimCity BuildIt, Size: 100M, Size_MB: 100.0
6 App: Talking Babsy Baby: Baby Games, Size: 100M, Size_MB: 100.0
7 App: Draft Simulator for FUT 18, Size: 100M, Size_MB: 100.0
8 App: The Walking Dead: Our World, Size: 100M, Size_MB: 100.0
9 App: Stickman Legends: Shadow Wars, Size: 100M, Size_MB: 100.0
10 App: Post Bank, Size: 100M, Size_MB: 100.0
11 App: Car Crash III Beam DH Real Damage Simulator 2018, Size: 100M, Size_MB: 100.0
12 App: Hungry Shark Evolution, Size: 100M, Size_MB: 100.0
13 App: Vi Trainer, Size: 100M, Size_MB: 100.0
14 App: Miami crime simulator, Size: 100M, Size_MB: 100.0
15 App: Gangster Town: Vice District, Size: 100M, Size_MB: 100.0
16 App: Hungry Shark Evolution, Size: 100M, Size_MB: 100.0
17 App: Navi Radiography Pro, Size: 100M, Size_MB: 100.0
18 App: Rope Hero: Vice Town, Size: 99M, Size_MB: 99.0
19 App: Miami Crime Vice Town, Size: 99M, Size_MB: 99.0
20 App: My Talking Angela, Size: 99M, Size_MB: 99.0
21 App: music (CG), Size: 99M, Size_MB: 99.0
```

2. Check whether each attribute has missingness. For those attributes that have missingness, present the attribute names and their number of missing values. (15%)

根據程式的執行結果，以下欄位存在缺失值（Missing Values）：

```
1 Attributes with missing values and their counts:
2 Rating: 1474
3 Type: 1
4 Content Rating: 1
5 Current Ver: 8
6 Android Ver: 3
```

其餘欄位未出現缺失值或缺失筆數為 0。

因此，我們可以得知：

- **Rating** 為缺失值最多的欄位，共有 1474 筆。
- **Type**、**Content Rating**、**Current Ver**、**Android Ver** 也各別存在少量缺失值。

這些資訊可作為後續處理缺失值（如刪除、插補或預設值替代）的依據。

3. Let's focus on the attribute "Rating".

```
1 ===== Before Cleaning =====
2 Rating column describe:
3   count    9367.000000
4   mean      4.193338
5   std       0.537431
6   min       1.000000
7   25%       4.000000
8   50%       4.300000
9   75%       4.500000
10  max       19.000000
11 Name: Rating, dtype: float64
12
13 [Before] Mean: 4.193338315362443
14 [Before] IQR: 0.5 (Q1=4.0, Q3=4.5)
15 [Before] Std: 0.5374313031477587
16
17 ===== Potential anomalies (before correction) =====
18                                     App  Rating
19 15  Learn To Draw Kawaii Characters    3.2
20 23      Mcqueen Coloring pages        NaN
21 87      RST – Sale of cars on the PCT    3.2
```

```

22 113      Wrinkles and rejuvenation      NaN
23 123      Manicure – nail design         NaN
24 ...      ...                          ...
25 10824      Cardio-FR                   NaN
26 10825      Naruto & Boruto FR           NaN
27 10831      payermonstationnement.fr    NaN
28 10835      FR Forms                    NaN
29 10838      Parkinson Exercices FR      NaN
30
31 [1978 rows x 2 columns]
32
33 ===== After Cleaning & Correction =====
34 Rating column describe:
35 count      8863.000000
36 mean        4.277446
37 std         0.357696
38 min         3.300000
39 25%         4.100000
40 50%         4.300000
41 75%         4.500000
42 max         5.000000
43 Name: Rating, dtype: float64
44 [After] Mean: 4.2774455601940655
45 [After] IQR:  0.400000000000000036 (Q1=4.1, Q3=4.5)
46 [After] Std:  0.3576960187482453

```

(1) Calculate its mean, IQR, and standard deviation. (10%)

```

1  根據程式執行後的 **Before Cleaning** 統計資訊，計算結果如下：
2
3  • **平均值 (Mean):** 4.193338315362443
4
5  • **四分位距 (IQR):** 0.5
6
7  • Q1 = 4.0
8
9  • Q3 = 4.5
10
11 • **標準差 (Std):** 0.5374313031477587

```

(2) Identify and report anomalies and/or errors in it. What would you do to make necessary corrections for it? (15%)

1. 異常值或錯誤值的判定

- 從統計摘要可見，Rating 最小值為 1.0，最大值竟達 19.0，遠超過合理的評分上限（通常為 5.0）。
- 此外也有部分資料顯示 NaN 或其他可能不合理之值。
- 綜合業務邏輯和 IQR 規則後，我們將「大於 5 或小於 1」的分數視為不合理，也將某些空白、無法轉成數值的 Rating 標記為缺失值（NaN）。

2. 更正方式

- 將判定為異常或不合理的 Rating 值改成 NaN（或於清理中予以刪除），即在程式中 `df.loc[~condition_final, "Rating"] = np.nan` 所示。
- 之後再進行統計計算時，就會先排除這些不合理的值。

(3) Following (2) after corrections being made, re-calculate the mean, IQR, and standard deviation. (15%)

根據 **After Cleaning & Correction** 統計資訊，排除或修正異常值後得到：

- **平均值 (Mean):** 4.2774455601940655
- **四分位距 (IQR):** 0.400000000000000036
- Q1 = 4.1
- Q3 = 4.5
- **標準差 (Std):** 0.3576960187482453

可觀察到異常值清除後，

- 平均值稍微上升至約 4.28；

- 標準差縮小到約 0.358，

顯示資料整體分布更加集中，且不合邏輯的極端值已被排除。

4. Let's focus on the chi-square test.

(1) Check online. What are the assumptions and limitations of the chi-square test?(15%)

1. 資料必須是類別型 (categorical data)：

例如「Rating ≥ 4 ：是/否」、「Price ≥ 100 ：是/否」等，才能用卡方檢定。

2. 隨機且獨立抽樣 (independence)：

每個觀察值應該來自獨立樣本，彼此不應相關或重複。

3. 理論次數 (expected frequencies) 不能過低：

一般建議每個儲格的期望次數不小於 5，或至少 80% 以上的儲格不小於 5。

4. 僅能用於判斷「是否有關聯」，不能解釋因果：

卡方檢定只顯示兩個變數之間有沒有關聯，並無法告訴我們誰影響誰，或影響程度的大小。

(2) Use the chi-square test to investigate the following: whether the ratings ≥ 4 or not is associated with whether the price ≥ 100 or not. Report on your test results. What is your conclusion? (20%)

```
1 Contingency table:
2 Price_100+ False True
3 Rating_4+
4 False      3459    13
5 True       7362     7
6 Chi-square test statistic: 8.54722541926516
7 p-value: 0.003460492769636125
8 Degrees of freedom: 1
9 Expected frequencies:
10 [[3.46559469e+03 6.40531316e+00]
11  [7.35540531e+03 1.35946868e+01]]
12
13 檢定結果: p-value < 0.05, 拒絕虛無假設(H0)
14 → 推論: Rating $\geq 4$  與 Price $\geq 100$  之間具有統計上的關聯
```

結論：

根據卡方檢定結果 (p-value < 0.05)，我們拒絕「評分 ≥ 4 與價格 ≥ 100 之間獨立」的虛無假設，表示在統計上這兩個變數有顯著關聯。從觀察值可看到，價格較高 (≥ 100) 的應用程式中，評分 ≥ 4 的比例相對較低；而價格較低 (< 100) 的應用程式則有較高比例達到評分 ≥ 4 。

換句話說，根據這份資料，**價格是否 ≥ 100 與應用程式評分是否 ≥ 4 並非獨立**，二者之間存在某種程度的負向關聯：價格越高的應用，越不容易有高評分。當然，這只是統計上的關聯，並不代表兩者必然存在因果關係。