

## 資料探勘-第一次作業

### 1. List the top 20 apps with the largest size. Present the app names and their size.

```
1 Top 20 Apps with the largest Size:
2 App: Mini Golf King – Multiplayer Game, Size: 100M, Size_MB: 100.0
3 App: Ultimate Tennis, Size: 100M, Size_MB: 100.0
4 App: Hungry Shark Evolution, Size: 100M, Size_MB: 100.0
5 App: SimCity BuildIt, Size: 100M, Size_MB: 100.0
6 App: Talking Babsy Baby: Baby Games, Size: 100M, Size_MB: 100.0
7 App: Draft Simulator for FUT 18, Size: 100M, Size_MB: 100.0
8 App: The Walking Dead: Our World, Size: 100M, Size_MB: 100.0
9 App: Stickman Legends: Shadow Wars, Size: 100M, Size_MB: 100.0
10 App: Post Bank, Size: 100M, Size_MB: 100.0
11 App: Car Crash III Beam DH Real Damage Simulator 2018, Size: 100M, Size_MB: 100.0
12 App: Hungry Shark Evolution, Size: 100M, Size_MB: 100.0
13 App: Vi Trainer, Size: 100M, Size_MB: 100.0
14 App: Miami crime simulator, Size: 100M, Size_MB: 100.0
15 App: Gangster Town: Vice District, Size: 100M, Size_MB: 100.0
16 App: Hungry Shark Evolution, Size: 100M, Size_MB: 100.0
17 App: Navi Radiography Pro, Size: 100M, Size_MB: 100.0
18 App: Rope Hero: Vice Town, Size: 99M, Size_MB: 99.0
19 App: Miami Crime Vice Town, Size: 99M, Size_MB: 99.0
20 App: My Talking Angela, Size: 99M, Size_MB: 99.0
21 App: music (CG), Size: 99M, Size_MB: 99.0
```

### 2. Check whether each attribute has missingness. For those attributes that have missingness, present the attribute names and their number of missing values. (15%)

根據程式的執行結果，以下欄位存在缺失值（Missing Values）：

```
1 Attributes with missing values and their counts:
2 Rating: 1474
3 Type: 1
4 Content Rating: 1
5 Current Ver: 8
6 Android Ver: 3
```

其餘欄位未出現缺失值或缺失筆數為 0。

因此，我們可以得知：

- **Rating** 為缺失值最多的欄位，共有 1474 筆。
- **Type**、**Content Rating**、**Current Ver**、**Android Ver** 也各別存在少量缺失值。

這些資訊可作為後續處理缺失值（如刪除、插補或預設值替代）的依據。

### 3.Let's focus on the attribute "Rating".

```
1  ===== Before Cleaning =====
2  Rating column describe:
3    count      9367.000000
4    mean        4.193338
5    std         0.537431
6    min         1.000000
7    25%         4.000000
8    50%         4.300000
9    75%         4.500000
10   max         19.000000
11   Name: Rating, dtype: float64
12
13   [Before] Mean: 4.193338315362443
14   [Before] IQR: 0.5 (Q1=4.0, Q3=4.5)
15   [Before] Std: 0.5374313031477587
16
17   ===== Potential anomalies (before correction) =====
18                                     App  Rating
19   15    Learn To Draw Kawaii Characters    3.2
20   23                Mcqueen Coloring pages    NaN
21   87    RST – Sale of cars on the PCT    3.2
22   113           Wrinkles and rejuvenation    NaN
23   123           Manicure – nail design    NaN
24   ...                                     ...
25   10824                  Cardio-FR    NaN
26   10825              Naruto & Boruto FR    NaN
27   10831    payermonstationnement.fr    NaN
28   10835                  FR Forms    NaN
29   10838      Parkinson Exercices FR    NaN
30
31   [1978 rows x 2 columns]
32
33   ===== After Cleaning & Correction =====
34   Rating column describe:
35     count      8863.000000
36     mean        4.277446
37     std         0.357696
38     min         3.300000
39     25%         4.100000
40     50%         4.300000
41     75%         4.500000
42     max         5.000000
43     Name: Rating, dtype: float64
44     [After] Mean: 4.2774455601940655
45     [After] IQR: 0.40000000000000036 (Q1=4.1, Q3=4.5)
46     [After] Std: 0.3576960187482453
```

#### (1) Calculate its mean, IQR, and standard deviation. (10%)

```
1  根據程式執行後的 **Before Cleaning** 統計資訊，計算結果如下：
2
3  • **平均值 (Mean):** 4.193338315362443
```

4	
5	• <b>**四分位距 (IQR):**</b> 0.5
6	
7	• Q1 = 4.0
8	
9	• Q3 = 4.5
10	
11	• <b>**標準差 (Std):**</b> 0.5374313031477587

## (2) Identify and report anomalies and/or errors in it. What would you do to make necessary corrections for it? (15%)

### 1. 異常值或錯誤值的判定

- 從統計摘要可見，Rating 最小值為 1.0，最大值竟達 19.0，遠超過合理的評分上限（通常為 5.0）。
- 此外也有部分資料顯示 NaN 或其他可能不合理之值。
- 綜合業務邏輯和 IQR 規則後，我們將「大於 5 或小於 1」的分數視為不合理，也將某些空白、無法轉成數值的 Rating 標記為缺失值（NaN）。

### 2. 更正方式

- 將判定為異常或不合理的 Rating 值改成 NaN（或於清理中予以刪除），即在程式中 `df.loc[~condition_final, "Rating"] = np.nan` 所示。
- 之後再進行統計計算時，就會先排除這些不合理的值。

## (3) Following (2) after corrections being made, re-calculate the mean, IQR, and standard deviation. (15%)

根據 **After Cleaning & Correction** 統計資訊，排除或修正異常值後得到：

- **平均值 (Mean):** 4.2774455601940655
- **四分位距 (IQR):** 0.40000000000000036
- Q1 = 4.1
- Q3 = 4.5
- **標準差 (Std):** 0.3576960187482453

可觀察到異常值清除後，

- 平均值稍微上升至約 4.28；
- 標準差縮小到約 0.358，

顯示資料整體分布更加集中，且不合邏輯的極端值已被排除。

## 4. Let's focus on the chi-square test.

### (1) Check online. What are the assumptions and limitations of the chi-square test?(15%)

1. 資料必須是類別型 (categorical data) :

例如「Rating $\geq 4$  : 是/否」、「Price $\geq 100$  : 是/否」等，才能用卡方檢定。

2. 隨機且獨立抽樣 (independence) :

每個觀察值應該來自獨立樣本，彼此不應相關或重複。

3. 理論次數 (expected frequencies) 不能過低 :

一般建議每個儲格的期望次數不小於 5，或至少 80% 以上的儲格不小於 5。

4. 僅能用於判斷「是否有關聯」，不能解釋因果 :

卡方檢定只顯示兩個變數之間有沒有關聯，並無法告訴我們誰影響誰，或影響程度的大小。

**(2) Use the chi-square test to investigate the following: whether the ratings $\geq 4$  or not is associated with whether the price $\geq 100$  or not. Report on your test results. What is your conclusion? (20%)**

```
1 Contingency table:
2   Price_100+   False   True
3 Rating_4+
4 False          3459    13
5 True           7362     7
6 Chi-square test statistic: 8.54722541926516
7 p-value: 0.003460492769636125
8 Degrees of freedom: 1
9 Expected frequencies:
10  [[3.46559469e+03  6.40531316e+00]
11   [7.35540531e+03  1.35946868e+01]]
12
13 檢定結果: p-value < 0.05, 拒絕虛無假設(H0)
14 → 推論: Rating $\geq 4$  與 Price $\geq 100$  之間具有統計上的關聯
```

**結論 :**

根據卡方檢定結果 (p-value < 0.05)，我們拒絕「評分 $\geq 4$  與價格 $\geq 100$  之間獨立」的虛無假設，表示在統計上這兩個變數有顯著關聯。從觀察值可看到，價格較高 ( $\geq 100$ ) 的應用程式中，評分 $\geq 4$  的比例相對較低；而價格較低 ( $< 100$ ) 的應用程式則有較高比例達到評分 $\geq 4$ 。

換句話說，根據這份資料，**價格是否  $\geq 100$  與應用程式評分是否  $\geq 4$  並非獨立，二者之間存在某種程度的負向關聯**：價格越高的應用，越不容易有高評分。當然，這只是統計上的關聯，並不代表兩者必然存在因果關係。